

Wykład 1

PRZEDMIOT INFORMATYKI

Informatyka - dziedzinna wiedza, która zajmuje się przetwarzaniem informacji - z uwzględnieniem ich procesów przetwarzania technicznych.

Informacja - [def. wg Kozmiewicza] wielkość abstrakcyjna, która może być przechowywana w pewnych obiektach, przetwarzana w pewnych obiektach, przesłana pewnymi pewnymi obiektami i stosowana do sterowania pewnymi obiektami. Przez obiekty rozumie się tutaj organizmy żywe, urządzenia techniczne, systemy oraz grupy takich obiektów.

Informacje są zgrupowane 3 podstawowe pojęcia:

- A. Komunikat - wyrażenie fizyczne informacji
- B. Kodowanie - zespół ogólnie przyjętych reguł
- C. Wiadomość - wyrażenie abstrakcyjne

dwadzieście pięć $\xrightarrow{\text{i polski}}$ lubo dwadzieście pięć

XXV $\xrightarrow{\text{system rzymski}}$ -11-

11001 $\xrightarrow{\text{s. dwójkowy}}$ -11-

twenty five $\xrightarrow{\text{i angielski}}$ -11-

25 $\xrightarrow{\text{s. dziesiętny}}$ -11-

2 Elementy ilościowej teorii informacji:

Problem jednoznacznego kodowania i rozkodowania informacji przy użyciu kodu binarnego (ciągów 01 (zero jedynkowych)) prowadzi do pojęcia kodu prefiksowego. Pod pojęciem kodu prefiksowego rozumiemy zbiór słów binarnych, w których każdy z tych ciągów binarnych nie jest początkiem innego ciągu.

WYKŁAD 2

Wzrost X oznacza zmienną losową przyjmującą wartości w skończonym zbiorze wiadomości $\{x_1, x_2, \dots, x_m\}$ i rozdzielcze prawdopodobieństwo

$$P[X = x_k] = p_k \text{ dla } k=1, 2, \dots, m.$$

Pojawia się x_k -ta wiadomość. Wzrost S oznacza funkcję prefiksowego kodowania binarnego na tym zbiorze wiadomości. Oznaczmy przez moduł $|S|$ funkcji długość kodu S , tzn. $|S(x_k)|$ jest długością kodu $S(x_k)$ reprezentującego wiadomość x_k dla $k=1, 2, \dots, n$.

Przez długość kodu rozumiemy liczbę znaków. Wówczas średnia długość kodu dla pary (X, S) jest równa $E(|S|) = \sum_{k=1}^n |S(x_k)| \times P[X = x_k] = \sum_{k=1}^n |S(x_k)| p_k$

Optymalny system kodowania jest tym lepszy im mniejsze jest średnie długość kodu $E(|S|)$.

Można dowieść następującej teorii nierówności dla dowolnego profilowanego kodu binarnego systemu S .

$$(2.1) \quad E(|S|) \geq H(\bar{X}) := \sum_{k=1}^m -P_k \log_2 P_k = \sum_{k=1}^m P_k \log_2 \frac{1}{P_k}$$

Przyjmujemy tutaj, że $0 \cdot \log_2 0 := 0$ i $0 \cdot \log_2 \frac{1}{0} := 0$, co jest naturalne z uwagi na równość

$$\lim_{t \rightarrow 0^+} t \log_2 t = \lim_{t \rightarrow 0^+} t \log_2 \frac{1}{t} = 0$$

Zauważmy, że $H(\bar{X})$ jest niezależna od systemu kodowania S . Zależy ona jedynie od rozkładu zmiennej losowej \bar{X} , czyli od rozkładu prawdopodobieństwa pojawienia się wiadomości x_k -tej, dla $k=1, 2, \dots, m$.

Liubo $H(\bar{X})$ nazywamy entropią informacyjną zmiennej losowej \bar{X} lub entropią informacyjną źródła informacji opisanego przez zmienną losową \bar{X} . Z uwagi na nierówność (2.1) entropię informacyjną $H(\bar{X})$ może być uważano jako teoretycznie możliwe najmniejszą średnią długość kodu dla wiadomości x_1, x_2, \dots, x_m .

Słowo teoretycznie pojawia się gdyż, równość w nierówności (2.1) nie zawsze może być osiągnięta dla zadanego rozkładu zmiennej losowej \bar{X} .

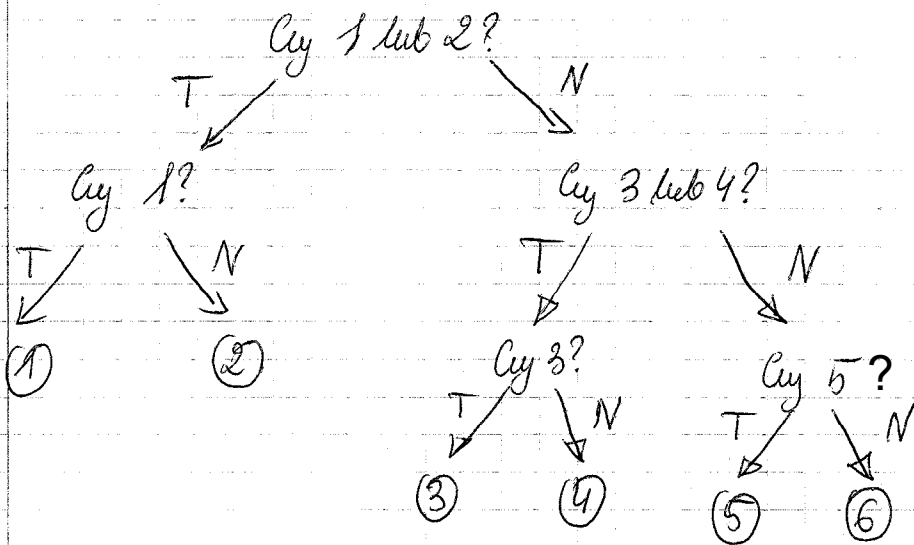
Przykład:

Pracujemy hostlis do gry. Włoch $x_k := k$ oznacza liubo wybranych arek dla $k=1, 2, 3, 4, 5, 6$. Mamy zatem $n=6$ wiadomości x_1, x_2, \dots, x_6 .


Dowolny funkcję prefiksowego kodowania binarnego S dla zbioru wiadomości można określić za pomocą tzw. binarnego systemu pytań. Tzn. systemu prowadzącego do identyfikacji każdej z tych wiadomości w wyniku zadawania skończonej ilości pytań na które można odpowiedzieć tak lub nie.

Rozważmy dwa systemy pytań:

I System



II System



$$S_1(x_1) := 11$$

$$S_2(x_1) := 1$$

$$S_1(x_2) := 10$$

$$S_2(x_2) := 011$$

$$S_1(x_3) := 011$$

$$S_2(x_3) := 010$$

$$S_1(x_4) := 010$$

$$S_2(x_4) := 001$$

$$S_1(x_5) := 001$$

$$S_2(x_5) := 0001$$

$$S_1(x_6) := 000$$

$$S_2(x_6) := 0000$$

Rozważmy sytuację, gdy kod jest symetryczny, tzn.

$$P[\bar{X} = x_k] = P_k = \frac{1}{6} \text{ dla } k=1,2,3,\dots,6, \text{ wówczas}$$

$$E(|S_1|) = \sum_{k=1}^6 |S_1(x_k)| P_k = \frac{1}{6} (2+2+3+3+3+3) = \frac{2}{3} = 2\frac{2}{3}$$

$$E(|S_2|) = \sum_{k=1}^6 |S_2(x_k)| P_k = \frac{1}{6} (1+3+3+2+4) = \frac{12}{6} = 3$$

$$E(|S_1|) = 2\frac{2}{3} < 3 = E(|S_2|)$$

Rozważmy teraz sytuację, gdy kod nie jest symetryczny i rozkład jest niesymetryczny: $P_1 = 0,95$, $P_k = 0,01$ dla $k=2,3,4,5,6$,

$$\text{wówczas: } E(|S_1|) = 2 \cdot 0,95 + (2+4 \cdot 3) \cdot 0,01 = 1,9 + 0,14 = 2,04$$

$$E(|S_2|) = 1 \cdot 0,95 + (3 \cdot 3 + 2 \cdot 4) \cdot 0,01 = 0,95 + 0,17 = 1,12$$

$$\text{Zatem } E(|S_1|) = 2,04 > 1,12 = E(|S_2|)$$

System S_1 jest gorszy od systemu S_2 , bo daje średnio dłuższy kod.

$$\text{W obu przypadkach entropia } H(\bar{X}_1) = \sum_{k=1}^6 P_k \log_2 \frac{1}{P_k} = \log_2 6$$

$$H(\bar{X}_2) = 0,95 \cdot \log_2 \frac{100}{95} + 0,05 \cdot \log_2 100$$

Pojęcie entropii inf. jest podstawowe dla teorii informacji.

Przyjmuje się że miernik ilości inf. zawartej w zbiorze wiadomości opisywanym przez zmienną losową X .

Skąd $P_k \cdot \log_2 \frac{1}{P_k}$ mierzony ilości informacji zawartej w wiadomości x_k -tej. Ilość inf. wyrażamy w jednostkach zwanych bitami, a w jednostkach pochodzących do bitów.

1 bit \rightarrow (1b) taki są pisać

1 bit \rightarrow odpowiada ilości informacji zawartej w dwóch jednakowo prawdopodobnych informacjach / wiadomościach.

$$P[X = x_k] = \frac{1}{2}, \text{ dla } k=1, 2, \dots, \text{ to } H[X] = \frac{1}{2} \log_2 2 + \frac{1}{2} \log_2 2 = \log_2 2 = 1$$

Jednostki pochodne

$$1B (1 \text{ bajt}) = 8b$$

$$1kB (1 \text{ kilobajt}) = 2^{10}B = 1024B$$

$$1MB (1 \text{ Megabajt}) = 2^{10}kB = 2^{20}B$$

$$1GB (1 \text{ Gigabajt}) = 2^{10}MB = 2^{30}B$$

$$1TB (1 \text{ Terabajt}) = 2^{10}GB = 2^{40}B$$

Pojęcie informacjiowe układu pamięciowego:

Ściśle, że dany jest układ pamięciowy V_N , w którym można zakodować N wartości x_1, x_2, \dots, x_N . Przyjmując, że zmienna losowa \bar{X} ma rozkład jednostajny, tzn. $P[X = x_k] = \frac{1}{N}$, dla $k=1, 2, \dots, N$ otrzymujemy równość

$$H(\bar{X}) = \sum_{k=1}^N p_k \log_2 \frac{1}{p_k} = \sum_{k=1}^N \frac{1}{N} \log_2 \frac{1}{1/N} = N \cdot \frac{1}{N} \log_2 N = \log_2 N$$

Skłóć $\log_2 N$ otrzymamy pojemność informacyjną układu pamięciowego V . Wyrażamy ją w jednostkach ilości informacji (b, B, kB, MB, GB, TB).

$$1b \rightarrow \log_2 N = 1 \rightarrow N = 2^1 = 2$$

$$1B \rightarrow \log_2 N = 8 \rightarrow N = 2^8 = 256$$